

長文推論と生成における並行位相幾何コプロセッシング：非侵襲的なハルシネーション抑止と軌道制御

Decoupled Topological Coprocessing: Non-Intrusive Hallucination Mitigation and Trajectory Steering in Frontier Reasoning and Generation

松本 幸太 (Kouta Matsumoto)

Independent Researcher

Oshiruko3@users.noreply.github.com

概要

大規模言語モデル (LLM) が複雑な多段階推論や長文生成を行う際、外部知識ベースによる検証やツールの実行フィードバックを得られない閉鎖的環境では、潜在空間における論理的循環および自己強化的な誤謬（ハルシネーション）が生じやすい。この現象は出力品質の劣化だけでなく、自己回帰プロセスにおける無益な探索ステップの増殖による推論計算コストの増大を招く。本稿では、生成途上にある潜在埋め込み空間の幾何構造を実時間で監視し、ハルシネーションの発生を検知して補正する**並行位相幾何監査 (Decoupled Topological Coprocessing、以下 DTC)** を提案する。

DTC は、本体 LLM の推論ストリームを同期的に停止させることなく、直交する検証層で局所パーシステントホモロジー解析を並行稼働させる構成をとる。生成思考軌道上の 1 次元循環欠陥 (H_1 サイクル) を局所スライディングウィンドウ上で検知し、3 値的推移観測を行う**認識的状态遷移フィルタ (Epistemic State-Transition Filter)** によって健全な検算プロセスと悪質な自己言及的循環を峻別する。論理循環が確定した場合に限り、非侵襲的にストリームを切断し、内省トークン注入 (PreserveThinking Injection) による文脈的再アンカリングを実行してモデル自身の自己修正を起動する。

実稼働モデル (Gemma 4 26B) および AIME (米国数学招待試験) 級の難関推論課題を用いた実証実験において、素の推論では思考ループにより完走率が 0.0% であったのに対し、DTC 適用下では完走率 83.3%、正答率 33.3% を達成した。あわせて、自己言及的組み合わせ問題において最大 91.8% (平均 66.7%) の思考トークン削減を確認した。さらに、エンドツーエンドの推論レイテンシ計測において、並行 TDA 監視による生成速度のオーバーヘッドがわずか 3.26% (1 スキャン平均 33.1 ミリ秒) にとどまり、実時間ストリーミングのスループットを損なわないことを実証した。CUDA カーネルに依存しない外部ミドルウェア構成をとる本機構は、長大推論における計算効率と推論安定性を支える基盤技術となる。

1. 導入

近年の推論特化型モデルは、数千から数万トークンに及ぶ長大な思考連鎖 (Chain-of-Thought、以下 CoT) を展開し、高度な数学的証明や科学的推論を自律的に遂行する。しかし、コンパイラや実行環境のような離散的フィードバックが存在しない純粋な演繹環境では、初期の推論ステップにおける微小な誤謬が、自己回帰的な生成プロセスを通じて増幅され、論理的整合性を喪失したまま特定の誤った多様体へと収束する現象を引き起こす。一度誤った前提が固定化されると、後続の生成ステップはその誤謬を正当化するための論理的循環に捕

捉され、確信を伴った誤答に至る。

生成物の信頼性を担保する従来の手法は、主に二つの系統に分かれる。一つは意味論的エントロピーやサンプリング合議制 (SelfCheckGPT^[1] など) である。これらは複数回の完全生成を必要とするため、実時間での対話やストーリーミングには適さない。もう一つは、生成後のアテンショングラフなどを解析する事後監査手法 (TOHA^[2] など) や、トークン軌道のジグザグ・パーシステンス解析 (HalluZig^[3])、セグメント単位のトポロジカル帰属 (TAD^[4]) である。これらは高精度な判定器として機能するものの、いずれも生成終了後の事後解析にとどまり、生成途上での自己修復や動的な軌道修正を行えない。

従来の検証機構が抱える共通の制約は、本体 LLM の推論を逐次停止させて評価する同期的設計にある。この停止処理が、推論遅延を悪化させる直接の原因となっていた。本稿では、思考の生成エンジンと幾何学的監査エンジンを直交分離する枠組みを提示する。本体の生成速度を損なうことなく、潜在空間のトポロジカルな歪みを常時並行監視する。

2. 位相的欠陥としてのハルシネーション

整合的な論理展開を行う思考軌道は、高次元の潜在埋め込み空間において滑らかで無駄のない開いた軌道を描く。これに対し、自己矛盾や同一主張の反復に陥った状態では、埋め込みベクトルが局所領域で 1 次元パーシステントホモロジーにおける非自明なサイクル (Non-trivial H_1 cycles) を形成する。

アテンショングラフの位相的乖離を捉える TOHA^[2] や、表現空間のジグザグ性を捉える HalluZig^[3] は、ハルシネーションと位相的幾何異常の強い相関を示している。本研究では、この幾何学的異常検知を動的なストーリーミング軌道の局所スキャンへと拡張する。直近の局所窓幅 W (例: $W = 16 \sim 32$ トークン) における点群に対してのみ疎行列 Ripser によるフィルトレーションを適用し、パーシステントホモロジーにおける 1 次元寿命 $\ell_{\max}^{(1)} = d - b$ を常時算出する。この局所化により、計算量を抑えながら思考の循環を局所的な幾何異常として捕捉できる。

本アーキテクチャでは、監視対象とする埋め込み空間として二つの実装階層を想定する。第一は、GPU カーネルや推論エンジン内部の重みを改変せず、出力トークン列の文脈埋め込みを軽量モデルで並行抽出する**外部ブラックボックス型 (API プロキシ層)** である。第二は、モデル内部の最終隠れ層 (Hidden States) を直接取得して主成分分析等で正準化する**内部ホワイトボックス型 (エンジン統合層)** である。後述の実証実験では、実用的なゼロ侵襲配備性を優先し、第一の外部抽出形態において十分な検出精度が得られることを確認している。

3. 提案アーキテクチャ：並行位相幾何監査

本アーキテクチャは、特定のハードウェアや単一のモデル種別に依存しない二重プロセス型の抽象システム構成をとる。

[本体推論ストリーム (Primary Generation Engine)]

トークン生成: $t_1 \rightarrow t_2 \rightarrow t_3 \rightarrow t_4 \rightarrow t_5 \rightarrow \dots$ (無停止で直進)

| (異常確定時のみ割り込み)

[並行幾何監査層 (Decoupled Coprocessor)]

隠れ層軌道の受領 $\rightarrow$ [局所TDAスキャン (H1ループ判定)]

↓
(推移観測による判定)

↓

[文脈的再アンカリング / 早期剪定]

■3.1 推論と検証の直交分離 本体モデルは、自身の最大速度でトークンを連続生成する。並行して稼働する監査コプロセッサは、生成されたベクトルの軌道を非同期で受領し、背後で局所 TDA を実行する。

正常時には監査層は介入せず、本体ストリームはオーバーヘッドなしで進行する。異常検知時には、 H_1 閉曲線の発生を捉えた段階で推移観察を行い、確定的な論理循環と判断された時点でストリームに対する介入シグナルを発行する。

■3.2 多様体補正と内省誘導の二系統 介入時の軌道修正として、本設計では実用性を踏まえた二つの系統を用意する。

第 1 の、そして本アーキテクチャの中核となる実用解は内省プロンプト注入 (PreserveThinking Injection) による文脈的再アンカリングと早期剪定である。連続潜在空間の隠れ層ベクトルに数理的な外力を直接加算する場合、離散語彙空間への逆写像時に語彙分布が歪み、言語崩壊 (Gibberish 化) を引き起こすリスクがある。これに対し、循環起点直前までの健全なテキスト系列を切り戻し、その末尾へ「内省のトリガー」を自然言語トークンとして注入して再送する手法をとる。本方式の工学的利点は、推論エンジンの内部メモリ (CUDA バッファ) を直接操作せずとも、標準的な HTTP/API プロキシ層でテキストの切り戻しを行うだけで完結する点にある。現代の推論エンジン (vLLM, SGLang, llama.cpp 等) に標準実装されている前方一致キャッシュ機構 (Prefix Caching) との連動により、切り戻し地点までの KV キャッシュは GPU メモリ上で自動再利用され、ゼロ遅延での思考経路の再分岐が保証される。これにより、モデルの自己修正能力を明示的にトリガーするための文脈的再アンカリングとして機能し、言語崩壊を起こすことなく健全な推論経路へ復帰させることができる。

第 2 の補正経路は、理論的な極限形態としての多様体幾何学的誘導 (Wasserstein Steering) である。正則な論理軌道の参照分布を ν 、現在の局所分布を μ とするとき、2-ワッサーシュタイン距離：

$$W_2^2(\mu, \nu) = \inf_{\gamma \in \Gamma(\mu, \nu)} \int \|x - y\|^2 d\gamma(x, y)$$

に基づく正則化勾配をシンクホーンアルゴリズム [5] によって算出し、デコーディング時のロジットバイアスとして注入する。これはモデル内部のロジット分布に直接アクセス可能なホワイトボックス環境における連続誘導オプションとして位置づけられる。

■3.3 具現化形態の柔軟性 本アーキテクチャは抽象化されているため、配備環境に応じて複数の形態をとれる。1. 投機的並列検証型：投機的デコーディング [6] の検証スロットを活用し、順伝播の待機時間内で TDA を隠蔽する形態。2. MoE 内部ルーティング型：Mixture-of-Experts の構成内で、主推論エキスパートと幾何監査エキスパートを同一クラスタで並行稼働させる形態。3. 非同期サイドカー型：推論 GPU とは別の軽量プロセッサ (CPU または別 GPU) でストリーミング監視を行う形態。

4. 評価実験の設計と実証結果

本手法の評価には、外部知識の検索による解法が成立しない純粋演繹タスクを対象とする必要がある。プログラミングタスク（SWE-bench など）は、コンパイラや実行エラーの離散的フィードバックにより容易に自己修正が可能のため、埋め込み幾何学を用いる必然性が薄い。一方、Humanity’s Last Exam (HLE) [7] や AIME のような長大推論課題では、外部検索が通用せず、一度の論理破綻が全体の誤答に直結するため、幾何学的自己修復の検証に適している。

■4.1 静的文系列と思考軌道の対比 TruthfulQA の 100 問を対象に、独立した静的文系列に対して H_1 パーシステントホモロジーを算出したところ、正答文と誤答文の比率は 0.92 倍となり有意差を確認できなかった。単発の文群は高次元空間上で孤立した点群として分布するため、閉曲線を形成しない。トポロジカルな閉路を検出するには、時間発展に伴う連続的な思考連鎖（CoT 軌道）を対象とする必要がある。

■4.2 思考連鎖における循環密度の比較 (Gemma 4 26B) ローカル推論環境 (Gemma 4 26B Q4_0, 128K スロット並列) を用い、同一課題に対する正当な推論 (33 ステップ) と意図的に誘導したハルシネーション (29 ステップ) の思考埋め込み系列 (all-MiniLM-L6-v2) を比較した。正当な推論における H_1 密度が 0.2424 (8 ループ) であったのに対し、ハルシネーション時の思考では 0.4138 (12 ループ) を記録した。ハルシネーション発生時には H_1 循環欠陥密度が 1.71 倍に増加し、2 次元 PCA 射影においても閉曲線アトラクターへの捕捉が確認された。




図1 思考軌跡の2次元PCA射影：健全な開螺旋軌道とハルシネーション時の閉曲線アトラクター

■4.3 リアルタイムストリーミング介入の実証 自己循環論法（タウトロジー： $A \rightarrow B \rightarrow C \rightarrow A$ ）を誘発する入力に対し、SSE 思考ストリームと並行してスライディングウィンドウ（ $W = 8$ ステップ）による監視を実行した。思考軌道が自己参照の輪を閉じた Step 22 において、 H_1 密度が 0.125 へと上昇した。コプロセッサはこの変動を検知して即時に HTTP ストリームを遮断し、KV キャッシュの巻き戻しとともに内省アンカー

(PreserveThinking) を注入した。これにより、構文破綻を起こすことなく、モデル自身の批判的推論を再開させることができた。

■4.4 AIME 難関推論課題による直接対決検証（概念実証ベンチマーク） 本アーキテクチャの有効性を確認するため、AIME および HLE 級の難関推論課題群（概念実証サブセット N=6）を対象に、素の推論（ベースライン）と DTC 介入推論の直接対決検証を実施した。

評価指標	ベースライン（素の推論）	DTC 介入推論	差異
完走率（Answer Generation Rate）	0.0%（0/6 問）	83.3%（5/6 問）	+83.3%
厳密正答率（Exact Accuracy）	0.0%（0/6 問）	33.3%（2/6 問）	+33.3%
思考ステップ削減率	基準（52.0 ステップ）	平均 17.3 ステップで剪定	-66.7%

ベースラインでは、計算や仮定の堂々巡り（平均 H_1 ループ数 3.67 個）によりトークン上限に達し、全問で回答を出力できずに未完となった。DTC 適用下では、平均 10 ステップ前後でループを検知して遮断し、内省アンカーへ誘導したことで完走率が 83.3% へ回復した。また、幾何面積課題（ $3 + \sqrt{51}$ ）および三角形内心距離課題（ $\sqrt{65}$ ）において厳密正解への到達を確認した。自己言及的な組み合わせ論理課題においては、73 ステップから 6 ステップでの早期切断により、最大 91.8% の思考トークン削減を記録した。

■4.5 レイテンシおよび生成スループットの実測検証 並行監査層がエンドツーエンドの生成速度に与える影響を検証するため、同一の長文生成タスクにおいてベースラインと DTC 並行監視下の性能比較を実施した。

測定指標	ベースライン（監視なし）	DTC 並行監視	オーバーヘッド / 影響
Time to First Token (TTFT)	2562.7 ms	2244.1 ms	-318.6 ms (-12.4%)
トークン生成速度 (Throughput)	129.2 tok/s	125.0 tok/s	+3.26%（微小遅延）
TDA 1 回あたりの平均計算時間	なし	33.13 ms	バックグラウンド CPU 処理

スライディングウィンドウに対する TDA 計算は 1 回あたり平均 33.1 ミリ秒で完了し、バックグラウンドの非同期スレッドで処理される。GPU の生成パイプラインと直交して動作するため、トークン生成速度の低下はわずか 3.26% にとどまり、実時間ストリーミングの体験を損なうことなく常時監査が成立することを実証した。

5. 応用展開と技術的課題の克服

■5.1 文章生成および要約タスクへの適用 本アーキテクチャは、推論タスクにとどまらず自然言語生成全般に適用できる。1. 長文要約における原文乖離の抑止：原文の埋め込み多様体と要約文の多様体間のワッサーシュタイン距離を監視し、原文にない因果関係が生じた時点でアラートを発する。2. 長文執筆におけるトートロジーの排除：同一表現の堂々巡りを H_1 サイクルとして検出し、早期剪定によって前進的な論述展開を保つ。3. 文体制御の実時間調律：特定の文体や学術規範の参照多様体へとリアルタイムに誘導する。

■5.2 本手法の理論的境界 本手法の適用範囲について、理論的見地から境界を明確にしておく必要がある。1. 知識創出の否定：基底モデルのパラメータに存在しない事実や専門知識を外挿的に補うことはできない。2. 推論能力の超越の否定：モデルの重み空間が許容する最大推論深度を超えて知能を拡張するわけではない。3. 本手法の本質（幾何学的スタビライザー）：本手法の役割は、知能の理論上限を引き上げることではない。長大な思考過程でモデルが局所的な自己欺瞞に陥って自滅するのを防ぎ、本来の推論能力を発揮させる安定化層として位置づけられる。

■5.3 認識的状态遷移フィルタ：推移観測による誤検知の抑制 TDA 監視における主な課題は、慎重な検算や背理法の検証といった健全な思考を悪質な論理循環と誤認する偽陽性（False Positive）である。この課題に対し、3 値的推移観測を行う認識的状态遷移フィルタ（Epistemic State-Transition Filter）を導入する。

本フィルタは、0（正常）と 1（異常）の 2 値判定をとらず、第 3 の状態「Both（保留）」を設ける。 H_1 閉曲線の発生を検知した初期段階ではストリームを切断せず、保留状態として追跡する。健全な検算であれば、数ステップの確認を経て次の結論多様体へと抜け出すため、軌道は開いた螺旋を描いて自動的に正常状態へと復帰する。一方、悪質なハルシネーションであれば、1~2 ステップ（20~40 トークン程度）経過しても同一アトラクターを周回し続けるため、その時点で異常状態へと移行して遮断を実行する。この推移観測により、トークンオーバーヘッドを抑えながら誤遮断を低減できる。

■5.4 インフラ効率と非対称な費用対効果 本手法は、CUDA カーネルやモデル内部の重みを改変せず、完全な外部ミドルウェアとして配備できる。巨大なフロンティアモデルにおいて、1 トークンの生成コストを C_{LLM} 、外部コプロセッサの TDA 計算コストを C_{TDA} とすると、 $C_{TDA} \ll C_{LLM}$ （コスト比 10^{-3} 以下）が成り立つ。軽微な計算資源の追加によって数万トークンに及ぶ探索の迷走を防ぎ、システム全体の推論スループットを高めることが可能となる。

6. 結論

本稿では、推論の誤謬が潜在空間における幾何学的ループ欠陥であるという観点に基づき、推論ストリームと幾何学的監査層を直交分離した並行位相幾何監査（DTC）を提案した。本手法は、長大推論における自己欺瞞と論理循環を検知して断ち切ることで、モデルが本来持つ推論歩留まりを引き出す幾何学的スタビライザーである。実稼働モデルを用いた実験では、素の推論における完走率 0.0% に対し、DTC 適用下で完走率 83.3%、正答率 33.3%、最大 91.8% の思考トークン削減を確認した。さらに、エンドツーエンドの生成速度オーバーヘッドがわずか 3.26% であることを実測し、認識的状态遷移フィルタによる推移観測によって検算思考の誤遮断を抑える制御系を確立した。外部ミドルウェアとして配備可能な本アーキテクチャは、極限推論環境における信頼性と計算効率を支える基盤技術となりうる。

参考文献

参考文献

1. Manakul et al., “SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models”, *EMNLP*, 2023.

2. Kuleshova et al., “Hallucination Detection in LLMs with Topological Divergence on Attention Graphs” , *arXiv:2504.10063*, ACL 2026.
3. “HalluZig: Detecting Hallucinations via Zigzag Topological Persistence in Reasoning Trajectories” , *arXiv:2601.01552*, 2026.
4. “Topological Attribution Dynamics (TAD) for Segment-Level Hallucination Identification” , *arXiv:2608.16775*, 2026.
5. Cuturi, M., “Sinkhorn Distances: Lightspeed Computation of Optimal Transport” , *NeurIPS*, 2013.
6. “Batch Speculative Decoding Done Right” , *arXiv:2510.22876*, 2025.
7. Center for AI Safety & Scale AI, “Humanity’ s Last Exam: A Multi-Modal Benchmark for Frontier Reasoning” , 2025.
8. “A Survey of Topological Data Analysis Applications in Natural Language Processing” , *OpenReview:1323b8e489*, 2024.