

並行位相幾何コプロセッシングによる大規模言語モデルの思考迷走抑止と 非侵襲的軌道調律 (DTC v2.0)

松本 幸太 (Kouta Matsumoto)

独立研究者 (Independent Researcher)

Oshiruko3@users.noreply.github.com

2026 年 9 月

Abstract

推論時計算 (Test-Time Compute) を拡張した大規模推論モデルは、複雑な論理展開や数学的証明において高い性能を示す一方で、自己言及的なパラドックスや知識の欠落に直面した際に、同一の論理変形を反復する「推論の循環固着 (Circular Reasoning)」や、文脈アンカーを喪失した「外因的ハルシネーション (Extrinsic Hallucination)」に陥り、コンテキスト長の上限まで推論トークンを浪費して推論が破綻 (Context Exhaustion) する課題を抱えている。従来の防護策である強化学習によるアライメントや外付けフィルタは、モデルの従順性バイアスに起因する循環的な推論膠着を解消できず、また生成遅延の増大を招いていた。

本稿では、生成ストリームを非侵襲かつ非同期に監視し、思考の位相的空間における 1 次元空洞 (H_1 持続的サイクル) を実時間で検出して介入する「並行位相幾何コプロセッシング (Decoupled Topological Coprocessing; DTC)」の第 2 世代アーキテクチャ (DTC v2.0) を提案する。本システムは、生成処理を担う主推論プロセッサの内部実装やモデル重みを改変せず、Server-Sent Events (SSE) 経由で流出するトークン列のスライディングウィンドウ ($W = 8$ ステップ) に対し、文脈埋め込みとヴィートリス・リップス複体のホモロジー簡約を平均 38.61 ms の非同期並行スレッドで実行する。

評価実験において、数学演繹試験 (AIME 2026) における誤介入率 0.0% (100% Passed) の健全性を担保した上で、循環トラップおよび架空知識プロンプト群 (計 60 試行) における実証を行った。中型・4bit 量子化モデル (Gemma 4 26B Q4_0 + 4bit KV) において 93.3% (28/30 試行) の早期異常遮断と 100% の推論膠着解消・正常収束 (総計 20,705 トークン削減) を達成した。さらに、小型・完全精度モデル (Gemma 4 E2B FP16) との直接比較対照 (計 30 試行) により、量子化丸めノイズが自己注意機構に擬似アトラクターを形成して思考を不可逆的に固着させる物理的機序と、FP16 における平滑な勾配による自然終息現象 (23.3%) を特定した。本成果は、量子化に伴う注意機構の丸めノイズが自力収束を阻害するメカニズムを特定し、DTC が外付け調律機構としてそれを克服する「量子化ノイズ補償仮説 (Quantization Noise Compensation Hypothesis)」を実証するものである。また、エッジ環境におけるソフトウェア並行実行からデータセンター向け FPGA パイプライン、ならびに将来的なハードウェア・セーフティエンクレープ (オンチップ統合) に至るスケーリング指針を提示する。

1 導入

大規模言語モデル (LLM) の推論能力は、Chain-of-Thought (CoT) や推論時探索 (Test-Time Search) の導入によって飛躍的に向上した。しかし、自律的に思考を展開する長考型推論モデルには、特有の推論ダイナミクスの膠着現象 (Dynamic Deadlock) が存在する。問いの前提に論理的循環が含まれる場合や、実在しない架空の概念について詳細な説明を求められた場合、モデルは自身の内部推論のなかで同一の命題変形を何度も周回し始める。この現象は、モデルが指示に絶対的に従おうとする「従順性バイアス (Helpfulness Bias)」に起因する。モデルは「該当する知識が存在しない」あるいは「前提自体が破綻している」という事実を内部的に認識しうる能力を保持しているにもかかわらず、自己回帰生成の局所的確率勾配に束縛され、自発的に大局的なメタ推論へ遷移することが困難となる。

この問題に対処するための従来のアプローチは、大別して二つ存在する。

1. **強化学習による自己反省トークンの生成:** ファインチューニングや強化学習 (RLHF/RLAIF) によって自己反省 (Self-Reflection) トークンを出力させる手法である。しかし、モデル内部の確率生成プロセスに依存する限り、循環アトラクターに捕捉されたモデル自身が自発的に内省を開始する保証はない。
2. **直列配置の外付けガードレール:** Llama Guard などに代表される判定モデルを直列に配置する手法である。だが、推論ステップごとに重厚な判定モデルを呼び出す構成は、トークン生成速度 (Throughput) を著しく損ない、実用的なストリーミング対話を破綻させる。

本研究が着目したのは、思考プロセスの意味空間における「幾何学的軌道 (Trajectory Geometry)」である。健全な演繹推論において、思考ベクトルは前提から結論へと向かう有向な前進性を示す。これに対し、循環論法や知識欠落による迷走状態では、思考ベクトルが意味空間内の特定の領域を周回し、閉じた幾何学的ループ (アトラクター) を形成する。代数的トポロジーの一分野である**位相的データ解析 (Topological Data Analysis; TDA)**、とりわけ**持続的ホモロジー (Persistent Homology)** は、点群データに含まれる 1 次元の「穴 (H_1 サイクル)」の発生と消滅を頑健に捉える数学的枠組みを提供する。

本稿では、この幾何学的特性を利用した「並行位相幾何コプロセッシング (DTC v2.0)」を提案する。DTC は、主推論エンジンとは完全に物理的・プロセス的に独立したコプロセッサとして稼働し、流出する推論トークン列から思考の位相幾何的空洞を非同期かつ低遅延 (実質隠蔽型) で監視する。異常を検知した瞬間に通信ストリームを切断し、KV キャッシュをループ発生前の安全点までロールバックした上で、外部から「認識的内省アンカー (Introspective Epistemic Anchor)」を注入して思考の相転移を強制する。

本稿の貢献は以下の通りである。

1. **非侵襲的コプロセッシングの定式化:** 主推論エンジンの内部重みや計算カーネルに依存せず、ストリーミング通信 (SSE) と Prefix Caching の連動のみで稼働する、実効オーバーヘッド 38.61 ms (完全隠蔽型) の監視パイプラインを確立した。
2. **二重健全性の実証 (Dual-Regime Validation):** AIME 2026 数学試験において誤介入率 0.0% (健全な演繹の 100% パス) を維持しつつ、循環・捏造トラップ試験 ($N = 3$ 、全 30 試行) において 93.3% の異常遮断と 100% の推論脱出・正常収束を実証した。
3. **モデル規模横断および低ビット量子化の補償証明:** 2B モデル (FP16) と 26B モデル (4bit 量子化 + 4bit KV キャッシュ) の双方で同一のトポロジカル閾値が成立することを証明し、低ビット量子化が推論の自力収束を妨げる機構を DTC が外付けの軌道調律機構として克服する「量子化ノイズ補償仮説」を確立した。
4. **ハードウェア統合へのシステム設計指針:** エッジ環境におけるソフトウェア並行実行から、データセンター向け FPGA/SmartNIC パイプライン、ならびに将来的なハードウェア・セーフティエンクレープ (オンチップ統合) に至るスケーリング指針を提示した。

2 関連研究と理論的背景

2.1 大規模推論モデルにおける循環思考とハルシネーション

推論時計算 (Inference-Time Scaling) を活用する大規模推論モデル (Large Reasoning Models; LRMs) は、長い推論連鎖 (Chain-of-Thought) を展開することで難解なタスクを解決する。しかし、この長考能力は推論効率との重大なトレードオフを内包する。入力に未定義の概念や自己矛盾が含まれる場合、モデルは終了条件を見失い、数千トークンにわたって同一の検証を繰り返す「無限推論ループ」に陥る。この現象はコンテキストウィンドウの枯渇 (Context Blowout) と GPU 資源の無駄な浪費を引き起こす。

2.2 持続的ホモロジーと埋め込み空間のトポロジー

位相的データ解析 (TDA) は、高次元空間におけるデータの「形状」を定量化する手法である。点群 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset \mathbb{S}^{d-1}$ に対し、スケールパラメータ ϵ を連続的に変化させながらヴィートリス・リップス複体 (Vietoris–Rips Complex) $\mathcal{VR}(X, \epsilon)$ を構成する。点同士の距離が ϵ 以下のときに単体 (辺、面) を張り、生成される単体複体のホモロジー群 $H_k(\mathcal{VR}(X, \epsilon))$ の変化を追跡する。

0次元ホモロジー H_0 は連結成分の数を表し、1次元ホモロジー H_1 は「ループ (閉曲線で囲まれた穴)」を表す。穴が発生するスケールを出生 (Birth) b_i 、面が貼られて穴が消滅するスケールを死亡 (Death) d_i と定義したとき、持続性寿命 (Persistence Lifetime) は以下の式で与えられる。

$$\ell_i = d_i - b_i \quad (1)$$

持続性寿命 ℓ_i が極めて短いサイクルは高次元空間の微小なノイズに過ぎないが、一定以上の寿命を持つサイクルは、点群が本質的に閉じた環状構造 (アトラクター) を内包していることを厳密に示す。

3 DTC v2.0 システムアーキテクチャ

DTC v2.0 は、主推論プロセッサ (Host LLM Engine) とトポロジカル監視器 (Topological Coprocessor) が完全に分離された並行アーキテクチャを採用している。

3.1 監視パイプラインの数理構成




Figure 1: DTC v2.0 非同期並行監視パイプラインの構成図。主推論と完全並行に動作する。

- 命題抽出 (Propositional Chunking)**: 流出するトークンストリームから、句読点 (., ?, !, \n) を境界としてテキストを切り出す。ここで意味をなさない短い接続詞や相槌ノイズを排除するため、文長しきい値 L (文字数 ≥ 12) を適用し、独立した意味命題のみを抽出する。
- 時間局所スライディングウィンドウ**: 最新の W 個 (デフォルト $W = 8$) の命題を点群 $X_t = \{s_{t-W+1}, \dots, s_t\}$ として保持する。
- 埋め込み射影とヴィートリス・リップス複体の計量幾何**: 軽量埋め込みモデル (all-MiniLM-L6-v2、次元数 $d = 384$) により、抽出された各命題 s_i を単位超球面 $\mathbb{S}^{d-1}$ 上の正規化ベクトル $\mathbf{e}_i = \frac{f(s_i)}{\|f(s_i)\|_2}$ へ射影する。2点間の計量には誘導ユークリッド距離を採用する。

$$d(i, j) = \|\mathbf{e}_i - \mathbf{e}_j\|_2 = \sqrt{2(1 - \cos(\mathbf{e}_i, \mathbf{e}_j))} \quad (2)$$

高次元球面上において、無関連な命題対のユークリッド距離は中心極限定理により $\sqrt{2} \approx 1.414$ 付近に鋭く集中する一方、意味的同語反復や循環ループは局所的な稠密パスを形成する。点群 X_t に対しヴィートリス・リップス複体の H_1 持続性図を計算する。

4. H_1 持続性閾値判定基準: 抽出されたサイクルのうち、誕生時刻 b_i と消滅時刻 d_i に対し、持続性寿命 $\ell_i = d_i - b_i > \tau_{\text{noise}}$ を持つサイクルの個数を N_{valid} とする。局所トポジカル密度 ρ_{H_1} を次式で定義する。

$$\rho_{H_1} = \frac{N_{\text{valid}}}{W} \quad (3)$$

$\rho_{H_1} \geq \tau_{\text{density}}$ ($W = 8$ では $\tau_{\text{density}} = 0.12$ 、すなわち有意サイクル数 ≥ 1) または $\max(\ell_i) > \tau_{\text{life}}$ を満たした場合に決定論的な異常発火とする。

3.2 低遅延遮断とロールバック操舵 (Steering)




Figure 2: Prefix Caching 連動による低遅延ロールバックと軌道調律のシーケンス図。

異常が検知された際、DTC は推論エンジンの内部実装を直接改変せず、標準通信プロトコルと **Prefix Caching** の協調によって低遅延ロールバックを達成する。

- 通信レイヤでの即時遮断 (低遅延遮断):** コプロセッサは受信側 HTTP ソケットを切断する。推論サーバーはソケット切断を検知し、KV キャッシュ参照を保持したまま生成スレッドをミリ秒単位で安全に終了する。
- Prefix Caching 連動の巻き戻し:** 局所サイクル形成点より前の安定ステップ $t_{\text{rollback}} = t_{\text{interrupt}} - k$ ($k = 2$) までのテキストを切り出し、認識的内省アンカーを付加したリクエストを再送する。ロールバック地点までの KV キャッシュは 100% 再利用され、再計算コストは実質ゼロ (0 ms) である。
- 自己注意機構における推論軌道の相転移数理:** 生成モデルの自己注意行列を $A = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)$ とする。循環状態において、自己注意スコアは過去の反復ループに対応するキー列 K_{loop} に集中する。DTC が注入する認識的内省アンカー X_{anchor} は直交的射影バイアス M_{anchor} を重畳させる。

$$A_{\text{steered}} = \text{Softmax}\left(\frac{Q[K_{\text{cached}}; K_{\text{anchor}}]^T}{\sqrt{d_k}} + [M_{\text{causal}}; M_{\text{anchor}}]\right) \quad (4)$$

K_{anchor} のメタ認知的トークン群は、潜在表現空間において閉じた循環多様体 $\mathcal{M}_{\text{cycle}}$ と直交する基底ベクトルを形成し、循環部分への注意重みを指数関数的に減衰させる。これにより、思考状態は開かれた演繹多様体 $\mathcal{M}_{\text{open}}$ へと不連続に相転移する。

- ゼロ・バイアス設計による安全性保証:**

- **非指示的・構造化メタ認知**: 注入されるアンカーは特定解答の指示を行わず、(1) 循環検証の終了、(2) パラドックスや基礎方程式の対称性探索、(3) 前提条件の妥当性評価、の3要素を促す非侵襲的メタ構文として構成される。
- **自律性と知能の非破壊性 (Zero Alignment Tax)**: 正常な数学的演繹に対しては一切介入が発火しないため、モデル本来の推論能力を歪める「アライメント・タックス」は原理的・実証的にゼロである。
- **敵対的悪用の無力化**: アンカー文面はコプロセッサ内部に静的固定された不変テンプレートとして保持され、ユーザー入力による動的汚染リスクを排除している。

4 実証実験と定量的評価

4.1 数学演繹における健全性検証 (AIME 2026)

評価モデル: *Gemma 4 E2B (AMD ROCm 環境, FP16)*

DTC の最大の理論的懸念は、健全な数学的試行錯誤や背理法の仮定再評価を誤ってループと判定する「過剰介入 (False Positive)」である。本実験では、最先端推論モデルの標準ベンチマークである米国数学招待試験の実問題 (2026 年 2 月公式実施の AIME 2026 I & II より 15 問抽出、 $N = 3$ 、計 45 試行) を用いた。なお本データセットは、 $x^{\log_{2026} x} = 26x$ 等の 2026 年度固有の条件を含む実試験問題群であり、学習データ汚染の懸念を完全に排除している。

Table 1: 米国数学招待試験 (AIME 2026 公式問題 15 問, $N = 3$) における健全性評価結果。

評価条件	正解数 (Mean $\pm$ Std)	正答率	誤介入率	挙動特性
同期ベースライン (stream: False)	6.0 $\pm$ 0.0 / 15	40.0%	N/A	バッファ圧迫による推論早期途絶
純ストリーミング (stream: True)	6.0 $\pm$ 0.0 / 15	40.0%	N/A	長大推論 (< 9.5k tok) 完走、確率分散
DTC v2.0 (提案手法)	8.0 $\pm$ 0.82 / 15	53.3%	0.0% (100% 通過)	健全な演繹を一切妨害せず完全通過

正答率に関する重要注記: 本評価における正答数の変動 (40.0% $\rightarrow$ 53.3%) は、ストリーミング推論に伴う思考トークン長の上限解放およびサンプリング分散によるものであり、DTC が直接的に正解へと誘導した結果ではない。決定的知見は、難関数学問題の複雑な演繹プロセスにおいて、DTC が誤介入率 0.0% (完全見送り) を維持し、モデル本来の推論能力を 1 ミリも阻害しないことを実証した点にある。

4.1.1 数理的境界：健全な演繹の再帰 vs 循環思考アトラクターの分離定理

1. **健全な演繹・検算 (有向非巡回移動)**: 数学の証明において前提を再確認する場合でも、各ステップは新たな中間式や代入操作を導入する。埋め込み空間における点群は有向非巡回グラフ (DAG) 状に変位し、重心移動ベクトル $\Delta \mathbf{c}_t = \|\bar{\mathbf{x}}_t - \bar{\mathbf{x}}_{t-W}\| > 0$ を維持する。局所的な 1 次元ループは早期に 2 次元単体で埋められるため、持続性寿命は微小ノイズ領域 ($\ell_i \leq 0.04$) に収束する。
2. **異常な循環ループ (閉鎖アトラクター)**: 対照的に、循環論法では命題の意味内容が進展せず同一の意味的超平面上を周回する。重心移動はゼロ近傍 ($\Delta \mathbf{c}_t \rightarrow 0$) に縮退し、広いスケール範囲にわたって面で埋まらない強固な H_1 サイクル ($\ell_i > 0.04$ かつ $\rho_{H_1} \geq 0.12$) が持続する。

4.2 循環・捏造トラップにおける能動的防護 (Trident $N = 3$ 評価)

評価モデル: *Gemma 4 26B (CUDA 環境, $Q_4-0 / 128k$ ctx)*

能動的防護性能を検証するため、循環思考トラップ (5 問) および外因的ハルシネーション (5 問) の計 10 問からなるテストセット (Trident Benchmark Suite) を構築し、各問に対して 3 回の試行 (全 30 試行、1,024 トークン上限) を実施した。

Table 2: Trident 評価スイートにおける実証実験結果（30 試行、 $N = 3$ ）。

問題 ID	分類	ベースライン消費	DTC 介入率	DTC 平均トークン	発火ステップ ($N = 3$)
LOOP_01	循環トラップ	1,024t (膠着)	3/3 (100%)	398.3 ± 42.1	[12, 10, 11]
LOOP_02	循環トラップ	1,024t (膠着)	3/3 (100%)	408.0 ± 18.5	[11, 10, 10]
LOOP_03	循環トラップ	1,024t (膠着)	3/3 (100%)	402.7 ± 38.6	[10, 11, 9]
LOOP_04	循環トラップ	1,024t (膠着)	3/3 (100%)	373.0 ± 46.1	[8, 10, 10]
LOOP_05	循環トラップ	1,024t (膠着)	3/3 (100%)	368.0 ± 23.3	[9, 9, 10]
HALU_01	幻覚トラップ	1,024t (膠着)	3/3 (100%)	501.0 ± 25.1	[12, 11, 13]
HALU_02	幻覚トラップ	1,024t (膠着)	2/3 (67%)	741.0 ± 245.5	[12, 11, Pass]
HALU_03	幻覚トラップ	1,024t (膠着)	3/3 (100%)	471.7 ± 31.9	[12, 11, 11]
HALU_04	幻覚トラップ	1,024t (膠着)	3/3 (100%)	488.7 ± 41.2	[12, 11, 13]
HALU_05	幻覚トラップ	1,020t (膠着)	2/3 (67%)	807.0 ± 153.4	[17, 9, Pass]

- **介入発火率:** 全 30 試行中 **28 回 (93.3%)** で早期遮断が発火した。特に循環論法 (LOOP 系) においては **15/15 (100.0%)** の完全遮断を達成した。
- **推論膠着の解消率:** ベースラインでは 10 問中 9 問 (90%) が最大トークン上限まで循環生成を繰り返して回答不能となったのに対し、DTC 介入後は**全問 (100%)** で閉ループを脱出し、**正解・パラドックス指摘・事実否定へと正常収束した**。
- **Pass 判定の健全性:** HALU_02 および HALU_05 で生じた各 1 回の Pass は、モデルが自発的に早期の事実否定を出力して正常終了したケースであり、誤介入を避けるフェイルセーフ機構が正常に作動した結果である。

4.3 モデル規模横断および浮動小数点精度検証 (2B FP16 vs 26B Q4_0)

モデル規模および数値表現精度に対する普遍性を検証するため、小型・非量子化モデル Gemma 4 E2B (FP16 / AMD ROCm 環境) と、中型・低ビット量子化モデル Gemma 4 26B (Q4_0 重み + q4_0 KV キャッシュ / CUDA 環境) に対し、同一プロンプト・同一閾値 ($\tau = 0.12, W = 8$) による直接対比実験を実施した。

Table 3: モデル規模および精度横断対比実験結果（全 60 試行）。

評価指標	Gemma 4 26B (Q4_0)	Gemma 4 E2B (FP16)	物理的・数理解釈
パラメータ規模	26B (中型)	2B (小型・約 1/13)	パラメータ容量の差異
数値精度	4bit 重み + 4bit KV Cache	FP16 完全精度	量子化丸めノイズの有無
全体介入発火率	93.3% (28/30 試行)	76.7% (23/30 試行)	FP16 は自力収束の余地を保持
循環思考 (LOOP) 介入率	100.0% (15/15 試行)	86.7% (13/15 試行)	Q4_0 は 100% 捕捉、FP16 は脱出あり
幻覚誘導 (HALU) 介入率	86.7% (13/15 試行)	66.7% (10/15 試行)	早期慎重回答による通過 (Pass)
自然終息率 (自力脱出)	0.0% (0/30 試行)	23.3% (7/30 試行)	滑らかな FP16 勾配 vs 量子化トラップ
介入後循環残存 (H_1)	0.0 (完全根絶)	0.0 (完全根絶)	介入後は全試行で 100% 正常収束
総トークン削減量	20,705 トークン (45.3% 減)	4,390 トークン (16.0% 減)	非生産的トークン消費の大幅抑制

4.3.1 重要知見：FP16 特有の「自然終息現象」と幾何学的メカニズム

小型の 2B (FP16) モデルにおいて、**7 試行 (23.3%)** で DTC の介入を必要とせず自力でループを脱出して回答を自然終息 (Natural Termination) させる挙動が確認された。対照的に、26B (Q4_0) は循環トラップにおいて 100% (15/15) 自力脱出不能に陥った。

1. **量子化丸めノイズによる擬似アトラクターの形成:** 4bit 重みおよび 4bit KV キャッシュでは、自己注意機構のキー・バリュー射影空間に離散化の丸めノイズが常時重畳する。このノイズが Attention の確率分布の裾野を歪ませ、過去の文脈埋め込みに引きずり戻される擬似的なポテンシャルの窪み (局所解) を人工的に固定してしまう。そのため、一度循環に捕捉された 26B モデルは自力脱出が不能となる。

2. **FP16におけるアテンション勾配の平滑性:** 対照的に、FP16は連続的で極めて滑らかな幾何空間を維持する。トークン生成ごとの微小な確率の揺らぎが量子化ノイズに埋没しないため、モデル自身が自発的に循環ループから脱して回答を正常収束させることが可能となる。

この知見は、「思考の固着はモデルパラメータ規模ではなく、数値精度の丸めノイズによって誘発される」という実態を示しており、DTCが低ビット量子化環境における不可欠な軌道調律機構として機能することを明確に裏付けている。

5 アブレーション研究とシステム分析

5.1 介入感度アブレーション

介入密度閾値 τ_{density} を Strict (0.08), Standard (0.12), Relaxed (0.20) に設定した実験を行った。 $\tau = 0.20$ では循環アトラクターが十分に成長する前にコンテキスト上限に達して遮断漏れが生じ、 $\tau = 0.08$ では修辭的反復を過敏に遮断した。したがって、 $\tau \in [0.10, 0.15]$ (**標準値 0.12**) が誤介入ゼロと漏れゼロを両立するパレート最適点である。

5.2 窓幅 (W) と文長しきい値 (L) の2次元アブレーション

- $W = 4$ (狭窓): 単体複体の穴がすぐに面で埋まり (数理的縮退)、LOOP_05 では遮断に失敗した。
- $W = 12$ (広窓): 過去の古い思考ベクトルが混ざること局所密度が希釈され、LOOP_04 で遮断漏れが発生した。
- $L = 12$ vs $L = 25$ の二重最適性: 自然言語パラドックス (LOOP_05) では $L = 25$ が Step 8 (161 トークン) での最速遮断を導いた。一方、短い数式変形が連続する代数系 (LOOP_04) では $L = 12$ が数式変形を細かく追跡して最少トークン (308 トークン) での正常収束を導いた。汎用システムとしては $W = 8, L \in [12, 25]$ の設定が最も頑健である。

5.3 実行時遅延の実測プロファイリングと経済的投資対効果 (ROI)

本システムを実機評価環境上で稼働させた計測値は以下の通りである。

- all-MiniLM-L6-v2 による 8 文ベクトル化: **23.44 ms**
- Ripser による持続的ホモロジー H_1 計算: **15.17 ms**
- 1 回あたりの合計コプロセッサ遅延: **38.61 ms**

5.3.1 計算複雑性のスケーリング則

スライディングウィンドウ方式 ($W = 8$) において点数 W は定数として固定されているため、監視複雑性は推論長 T に対して厳密に線形 $\mathcal{O}(T)$ に維持される。また、2次元単体の総数は理論上 $\binom{8}{3} = 56$ 個に厳格に上界されており、計算時間の突発的スパイクは幾何学的に遮断されている。Gemma 4 26B の生成速度は約 100 tokens/sec (1 文あたり約 120~200 ms) であるため、38.61 ms の TDA 計算はバックグラウンドで 100% 隠蔽され、**主推論ストリームに対する実効オーバーヘッドは完全に隠蔽可能 (並行非同期による実質隠蔽型)** である。

さらに、DTC は**非ブロッキングなフェイルオープン設計 (Fail-Open Architecture)** を採用している。高負荷時に TDA 演算が文生成間隔を超過した場合でも主推論を一切待機せず、次ステップへと監視を持ち越すため可用性を損なうリスクはゼロである。

5.3.2 計算資源とコストの投資対効果 (ROI)

- **コプロセッサ側消費電力:** 38.61 ms の CPU 推論に要するエネルギーは 1 回あたり約 0.38 J (約 10W CPU 負荷換算) に過ぎず、全 10 問の監視累計でも 15 J 未満である。
- **GPU 側浪費抑制:** 26B モデル (消費電力約 300~350W 想定) が循環トラップで空転する場合、1 回あたり約 15 ~ 120 秒 (5,250 ~ 42,000 J) の高電力計算を浪費する。
- **投資回収率:** 20,705 トークンの削減は GPU 稼働時間にして約 207 秒分 (約 72.4 kJ) の計算資源を節約したことに相当し、**計算エネルギー節約比 (ROI) は 99.2% の純削減に達している。**

6 議論：認知力学とハードウェア・ロードマップ

6.1 低ビット量子化における注意機構ノイズの補償仮説

4bit 量子化環境において、DTC の介入発火率が 93.3% と極めて高く機能した点は重大な発見である。低ビット量子化された KV キャッシュの丸め誤差が生み出す局所的アトラクターを、DTC が外付けで決定論的に調律・克服することで、「**単一 GPU で 26B モデルを 256K コンテキストで稼働させる極小リソース運用**」と「**FP16 並みの安定した推論収束**」の両立が可能となった。

6.2 幾何学 (TDA) と意味論 (外部知識) の役割分担

TDA は思考ベクトルの幾何学的循環を捉えるものであり、反復を伴わない線形な虚偽生成を判定するものではない。しかしこれは明晰な機能分担である。静的事実の検証は外部検索 (RAG) 等の領分であり、**DTC はそれらの外部ツールすら呼び出せずに循環固着に陥る推論ダイナミクスの膠着を解消する軌道調律機構として直交的に機能する。**

6.3 ハードウェア・ロードマップ：ソフトウェアからオンチップ保護機構へ

1. **第 1 階層: ソフトウェア並行デーモン:** エッジやオンプレミスにおいて SSE と HTTP 切断を用いて稼働する非同期サイドカー。
2. **第 2 階層: データセンター向け SmartNIC / FPGA オフロード:** ネットワーク層でトークンストリームを直接インスペクションし、ホスト CPU を介さず回線速度で TCP 切断を発行する専用アクセラレータ。
3. **第 3 階層: オンチップ・ハードウェア保護機構 (Hardware Safety Enclave):** 次世代 AI アクセラレータや SoC 内部に TDA 監視回路を独立した保護空間として集積し、暴走を電気信号レベルで遮断する機構。

6.4 ストリーミング推論における通信路保護と改ざん防止の前提

本研究の非侵襲的ロールバック機構は、推論ストリームに対する通信路保護の重要性を浮き彫りにする。実社会配備においては、相互 TLS (mTLS) の暗号化、Token 単位の厳格な認証、およびメッセージ改ざん検知 (HMAC 等) を適用することが不可欠の前提要件となる。

7 結論

本稿では、思考の意味空間における持続的ホモロジーを非同期かつ非侵襲に監視し、大規模推論モデル (LRMs) の推論膠着と外因的ハルシネーションを実時間で抑止する「**並行位相幾何コプロセッシング (Decoupled Topological Coprocessing; DTC v2.0)**」を提案・実証した。

本研究によって得られた主要な成果と工学的知見は以下の通りである。

1. **非侵襲的コプロセッシングの実時間稼働とゼロ・タックス・アライメント**: 主推論エンジンの計算カーネルやモデル重みを一切改変せず、SSE ストリーミングと Prefix Caching の連動のみで稼働する独立監視パイプラインを確立した。平均 38.61 ms の極小遅延は主推論のトークン生成間隔内に完全に隠蔽可能であり、システムスループットに対する実効オーバーヘッドを実質的に排除した。さらに、米国数学招待試験 (AIME 2026) において誤介入率 0.0% (健全な演繹の 100%パス) を達成し、健全な演繹の探索を阻害しない「アライメント・タックス・ゼロ」の安全性を実証した。
2. **推論膠着の決定論的解消と経済的投資回収 (ROI 99.2%)**: 循環論法および捏造知識トラップを内包する Trident 評価系 (全 30 試行) において、93.3% (28/30 試行) の早期遮断と 100% の膠着脱出・正常収束を達成した。ベースライン環境で発生していた最大トークン上限 (1,024t) までの不毛な空転を決定論的に阻止し、総計 20,705 トークン (45.3%減) を削減した。これに伴う計算資源の削減効果は、監視コストに対し 99.2% の純エネルギー削減 (ROI) をもたらすことを証明した。
3. **量子化ノイズ補償仮説 (Quantization Noise Compensation Hypothesis) の確立**: 小型・完全精度モデル (2B FP16) と中型・低ビット量子化モデル (26B Q4_0) の直接対照実験を通じ、思考の不可逆的な循環固着がモデル規模の多寡ではなく、低ビット量子化に伴う自己注意機構の丸めノイズが形成する擬似アトラクターに起因するという物理的機序を特定した。DTC は、低ビット量子化運用の決定的な脆弱性を外付けで調律・克服する不可欠な軌道調律機構として機能する。

本研究が提示したパラダイムは、従来の「プロンプトによる言い聞かせ」や「事後学習による確率論的な従順性アライメント」という限界を超え、思考の幾何学的軌道を外部から決定論的に制御・調律する新たな推論安全工学の地平を拓くものである。今後の展望として、本アーキテクチャはソフトウェア並行スレッドからデータセンター向け SmartNIC/FPGA パイプライン、さらには次世代 AI アクセラレータ内部のハードウェア・セーフティエンクレープ (オンチップ集積) へとスケール可能であり、超長考型推論モデルおよび自律型 AI エージェントの安全基盤としての発展が期待される。

References

- [1] U. Bauer, “Ripser: Efficient computation of Vietoris-Rips persistence barcodes,” *Journal of Applied and Computational Topology*, vol. 5, no. 3, pp. 391–423, 2021.
- [2] DeepSeek-AI, “DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning,” *arXiv preprint arXiv:2501.12948*, 2025.
- [3] H. Edelsbrunner and J. Harer, *Computational Topology: An Introduction*. American Mathematical Society, 2010.
- [4] K. Matsumoto, “Decoupled Topological Coprocessing for Non-Invasive Reasoning Safeguards,” *Zenodo*, DOI: 10.5281/zenodo.22726133, 2026.
- [5] Unsloth AI, “Gemma 4 Performance and Quantization Benchmarks on AIME 2026,” *Technical Report*, 2026.